

Grupo #6

Colorización de imágenes

*Generación de color en imágenes
en escala de grises utilizando
GANs*

Proyecto final Deep Learning



¿Cuál es el problema?

La colorización de imágenes en escala de grises busca recuperar colores realistas a partir del contenido y contexto visual. Este proceso, antes manual y complejo, tiene aplicaciones en restauración y análisis de imágenes. Nuestro objetivo es crear un sistema de deep learning que lo realice automáticamente con resultados coherentes y naturales.





Propuesta de solución

Nuestra propuesta implementa una Red Generativa Adversaria (GAN) para colorización automática, donde un generador basado en U-Net produce los canales de color a partir de la luminancia, y un discriminador tipo PatchGAN evalúa el realismo local de las imágenes para mejorar los resultados.

01.

Datos

Imágenes 128x128
Encoding LAB (en lugar de RGB)
Clases y labels

02.

Generador

Encoder-Decoder
Mecanismos de atención
VGG16 + UNET

03.

Discriminador

PatchGAN
Evaluación local por patches (14x14)
Label smoothing y estabilización

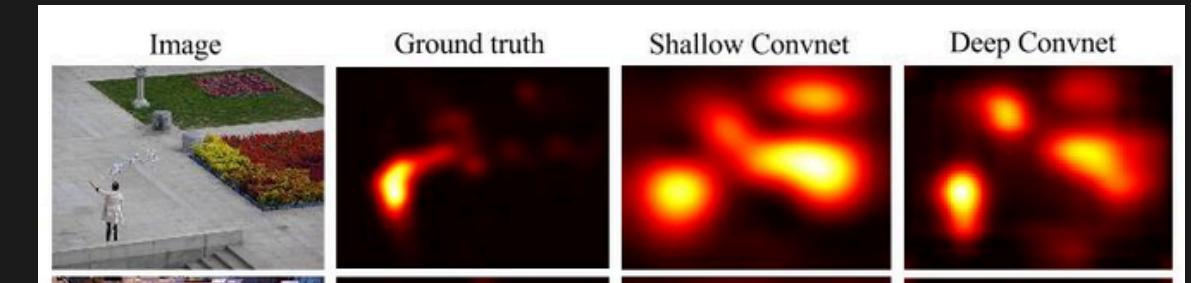
Más sobre la solución...

Encoding de Color



- El encoding LAB nos permite utilizar la escala de grises como un canal de color L (luminosidad).
- Esto reduce los canales del generador a solo A y B.
- Menos data, menos complejidad innecesaria y menos espacio para cometer errores

Saliency Maps



- Mapas de saliencia para identificar qué partes de la imagen el modelo considera más relevantes.
- El análisis se basa en los gradientes del discriminador respecto a la imagen de entrada.
-

DATA

01

DATASET ORIGINAL

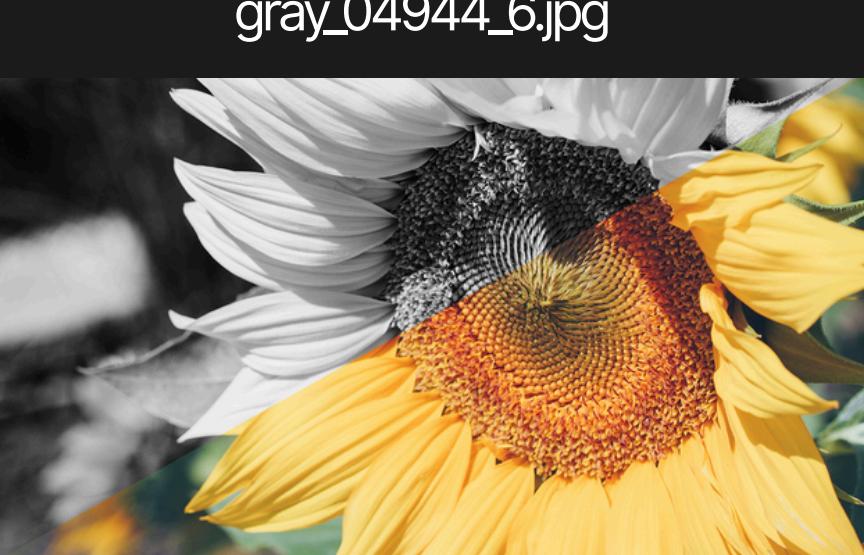
- Fuente: [Natural Images Kaggle](#)
- 6,899 imágenes en 8 clases: Airplane, Car, Cat, Dog, Flower, Fruit, Motorbike, Person
- Imágenes recopiladas de varios datasets públicos (ImageNet, PASCAL VOC, Stanford Cars)
- Análisis exploratorio: distribución de clases equilibrada, tamaños variables (43×50 px a 2737×2665 px), relación ancho/alto promedio 1.36



02

PREPROCESAMIENTO

- Redimensionamiento a 128×128 px con padding para mantener proporciones
- Conversión a escala de grises para entrada del modelo
- Renombrado y estandarización de archivos (.jpg)
- Data augmentation: rotaciones, volteos, brillo/contraste, recortes y escalado



03

DATASET FINAL

- Conjunto uniforme y balanceado, listo para entrenamiento y validación
- Cada imagen tiene par alineado: versión a color + versión en gris
- Guardado en carpetas separadas: ImagesProcessed/color y ImagesProcessed/gray
- Total: 6,899 pares de imágenes, categorizadas por clase y consistentes para la GAN



Herramientas utilizadas

01.



LManejo de imagenes

02.



Red neuronal

Texto del párrafo

03.



Pesos y librerias utiles

04.

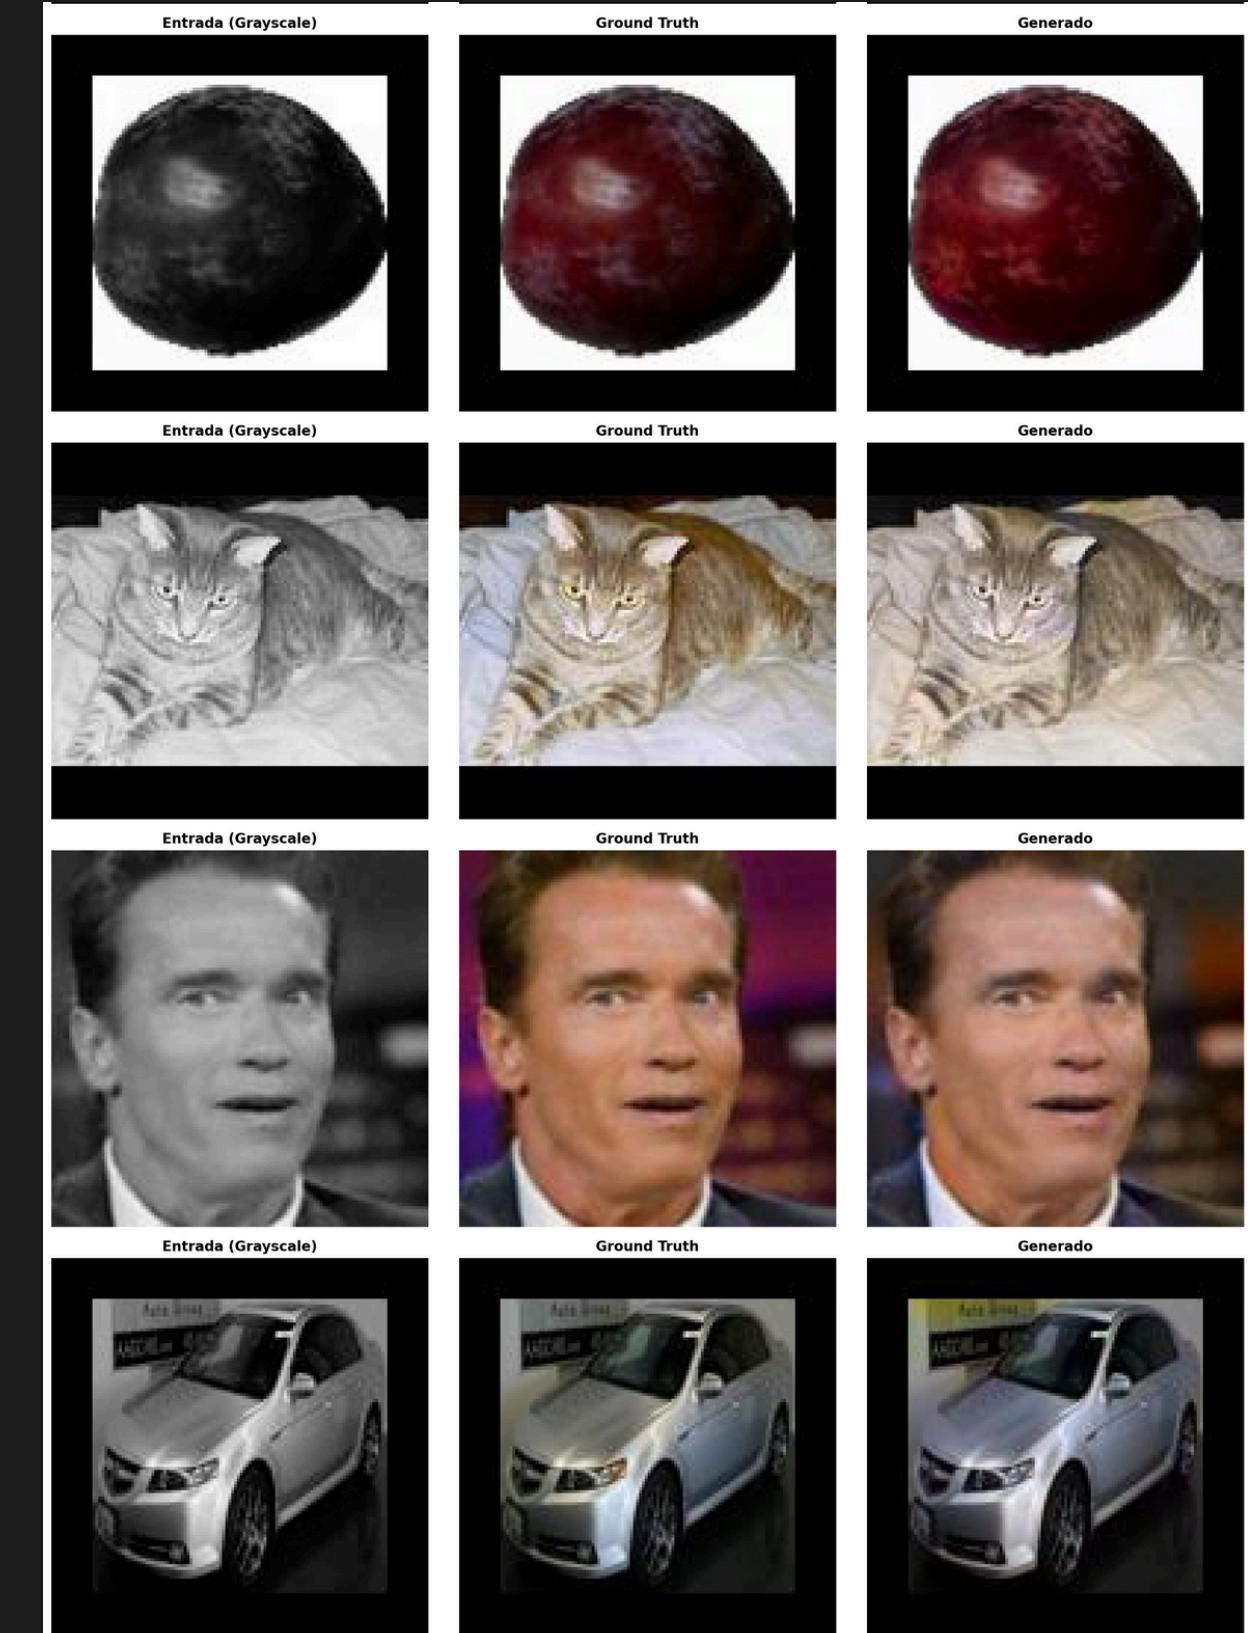
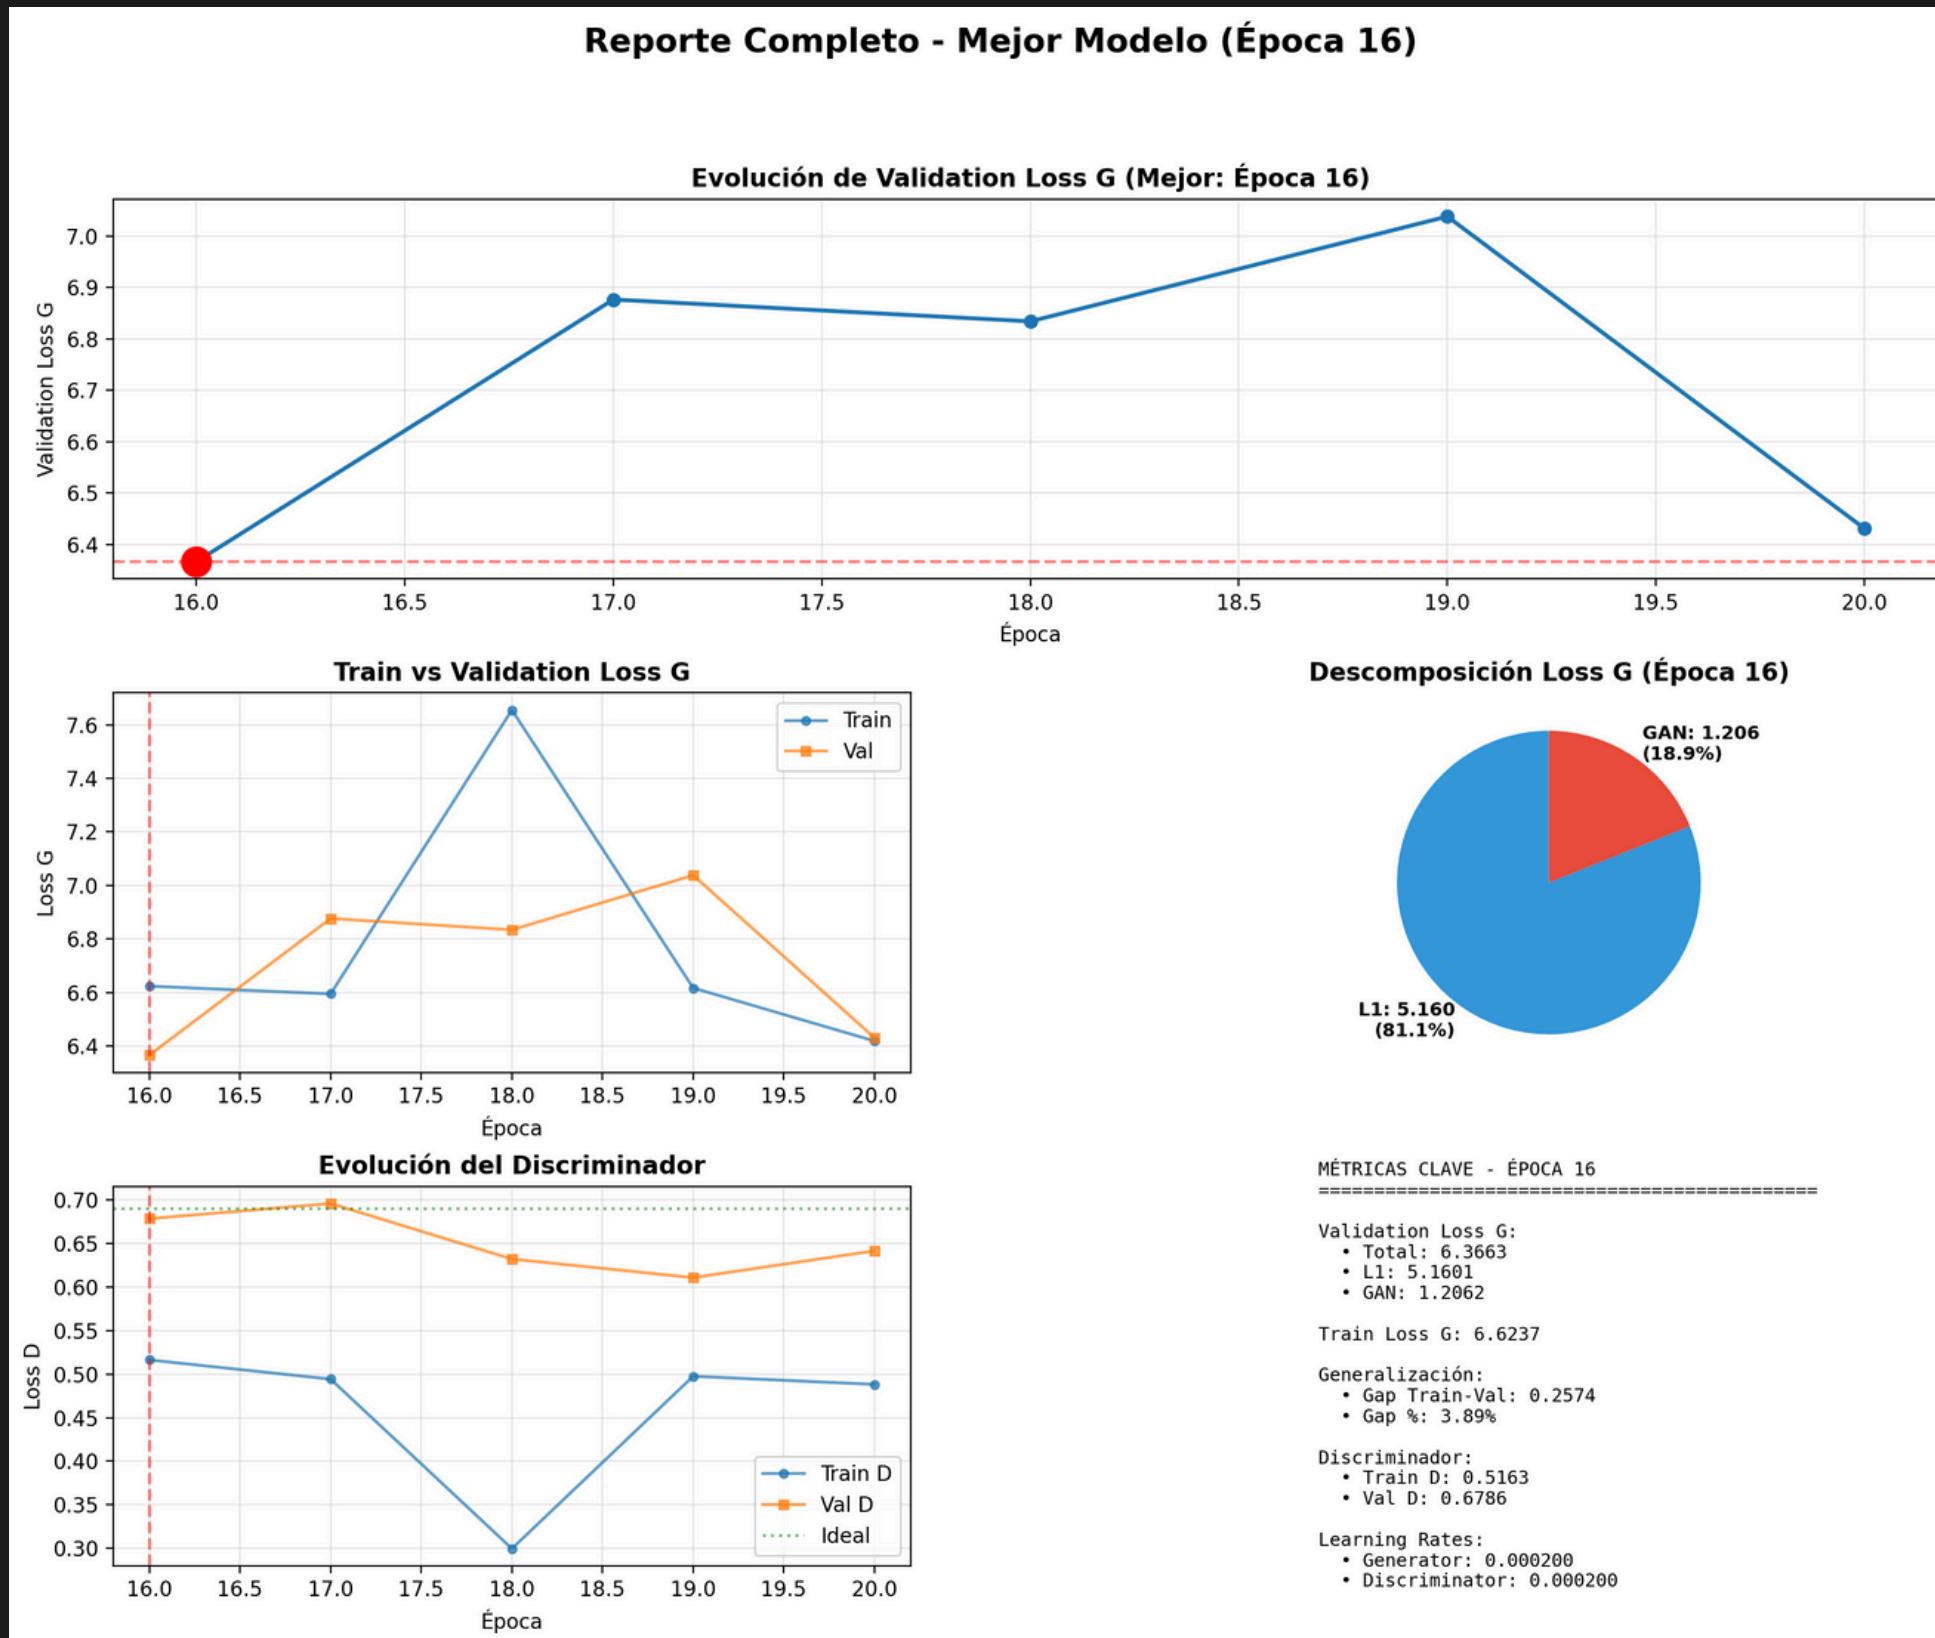


TensorBoard

TensorBoard, Monitoreo en
tiempo real del entrenamiento

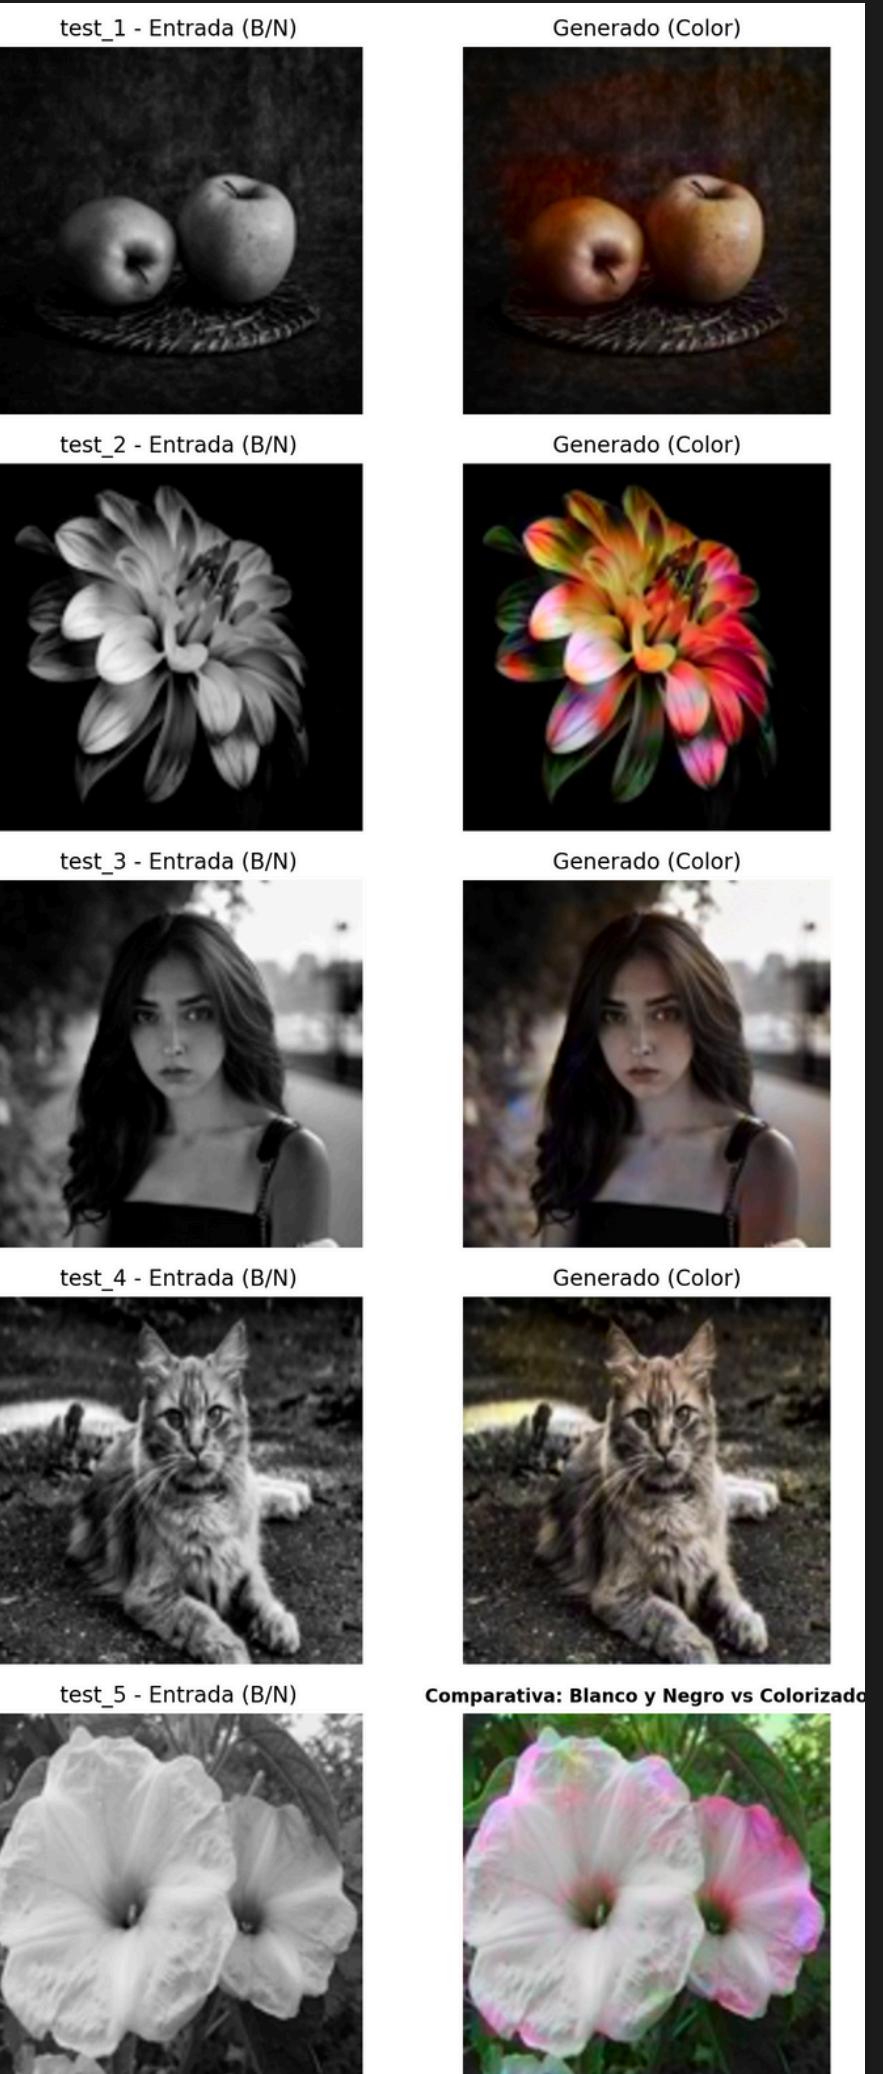
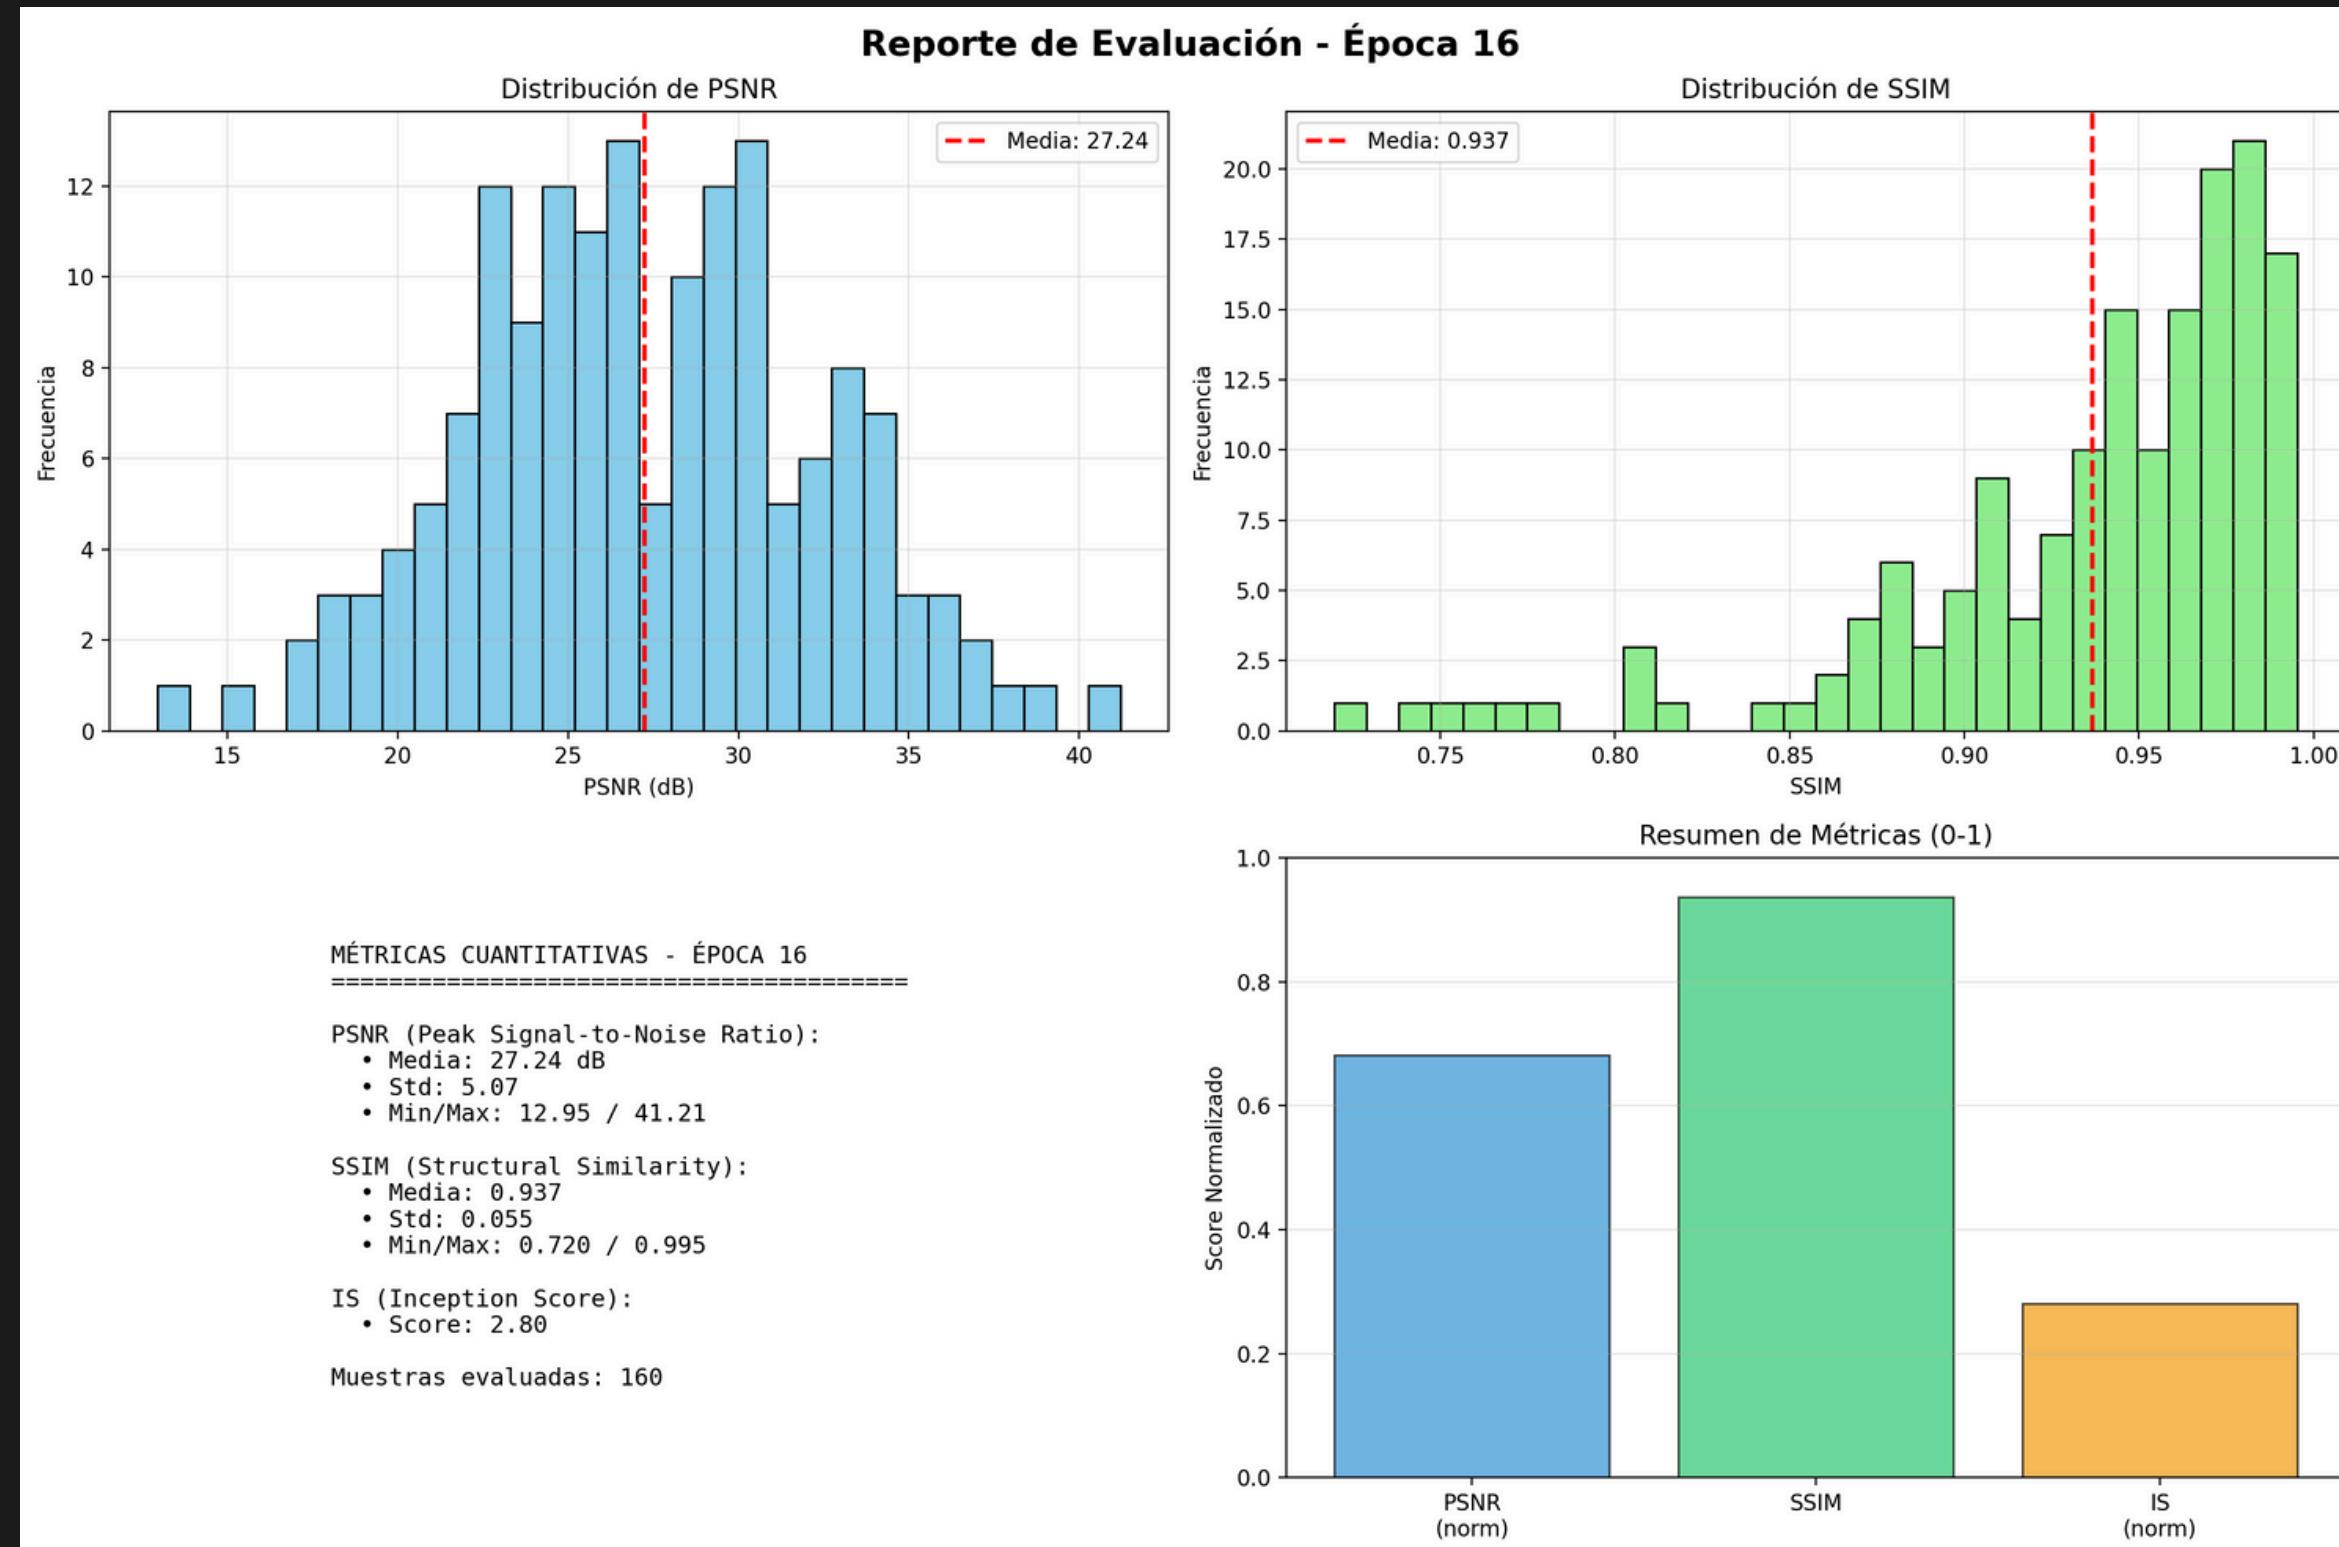
Resultados

Evolución del entrenamiento y desempeño del modelo



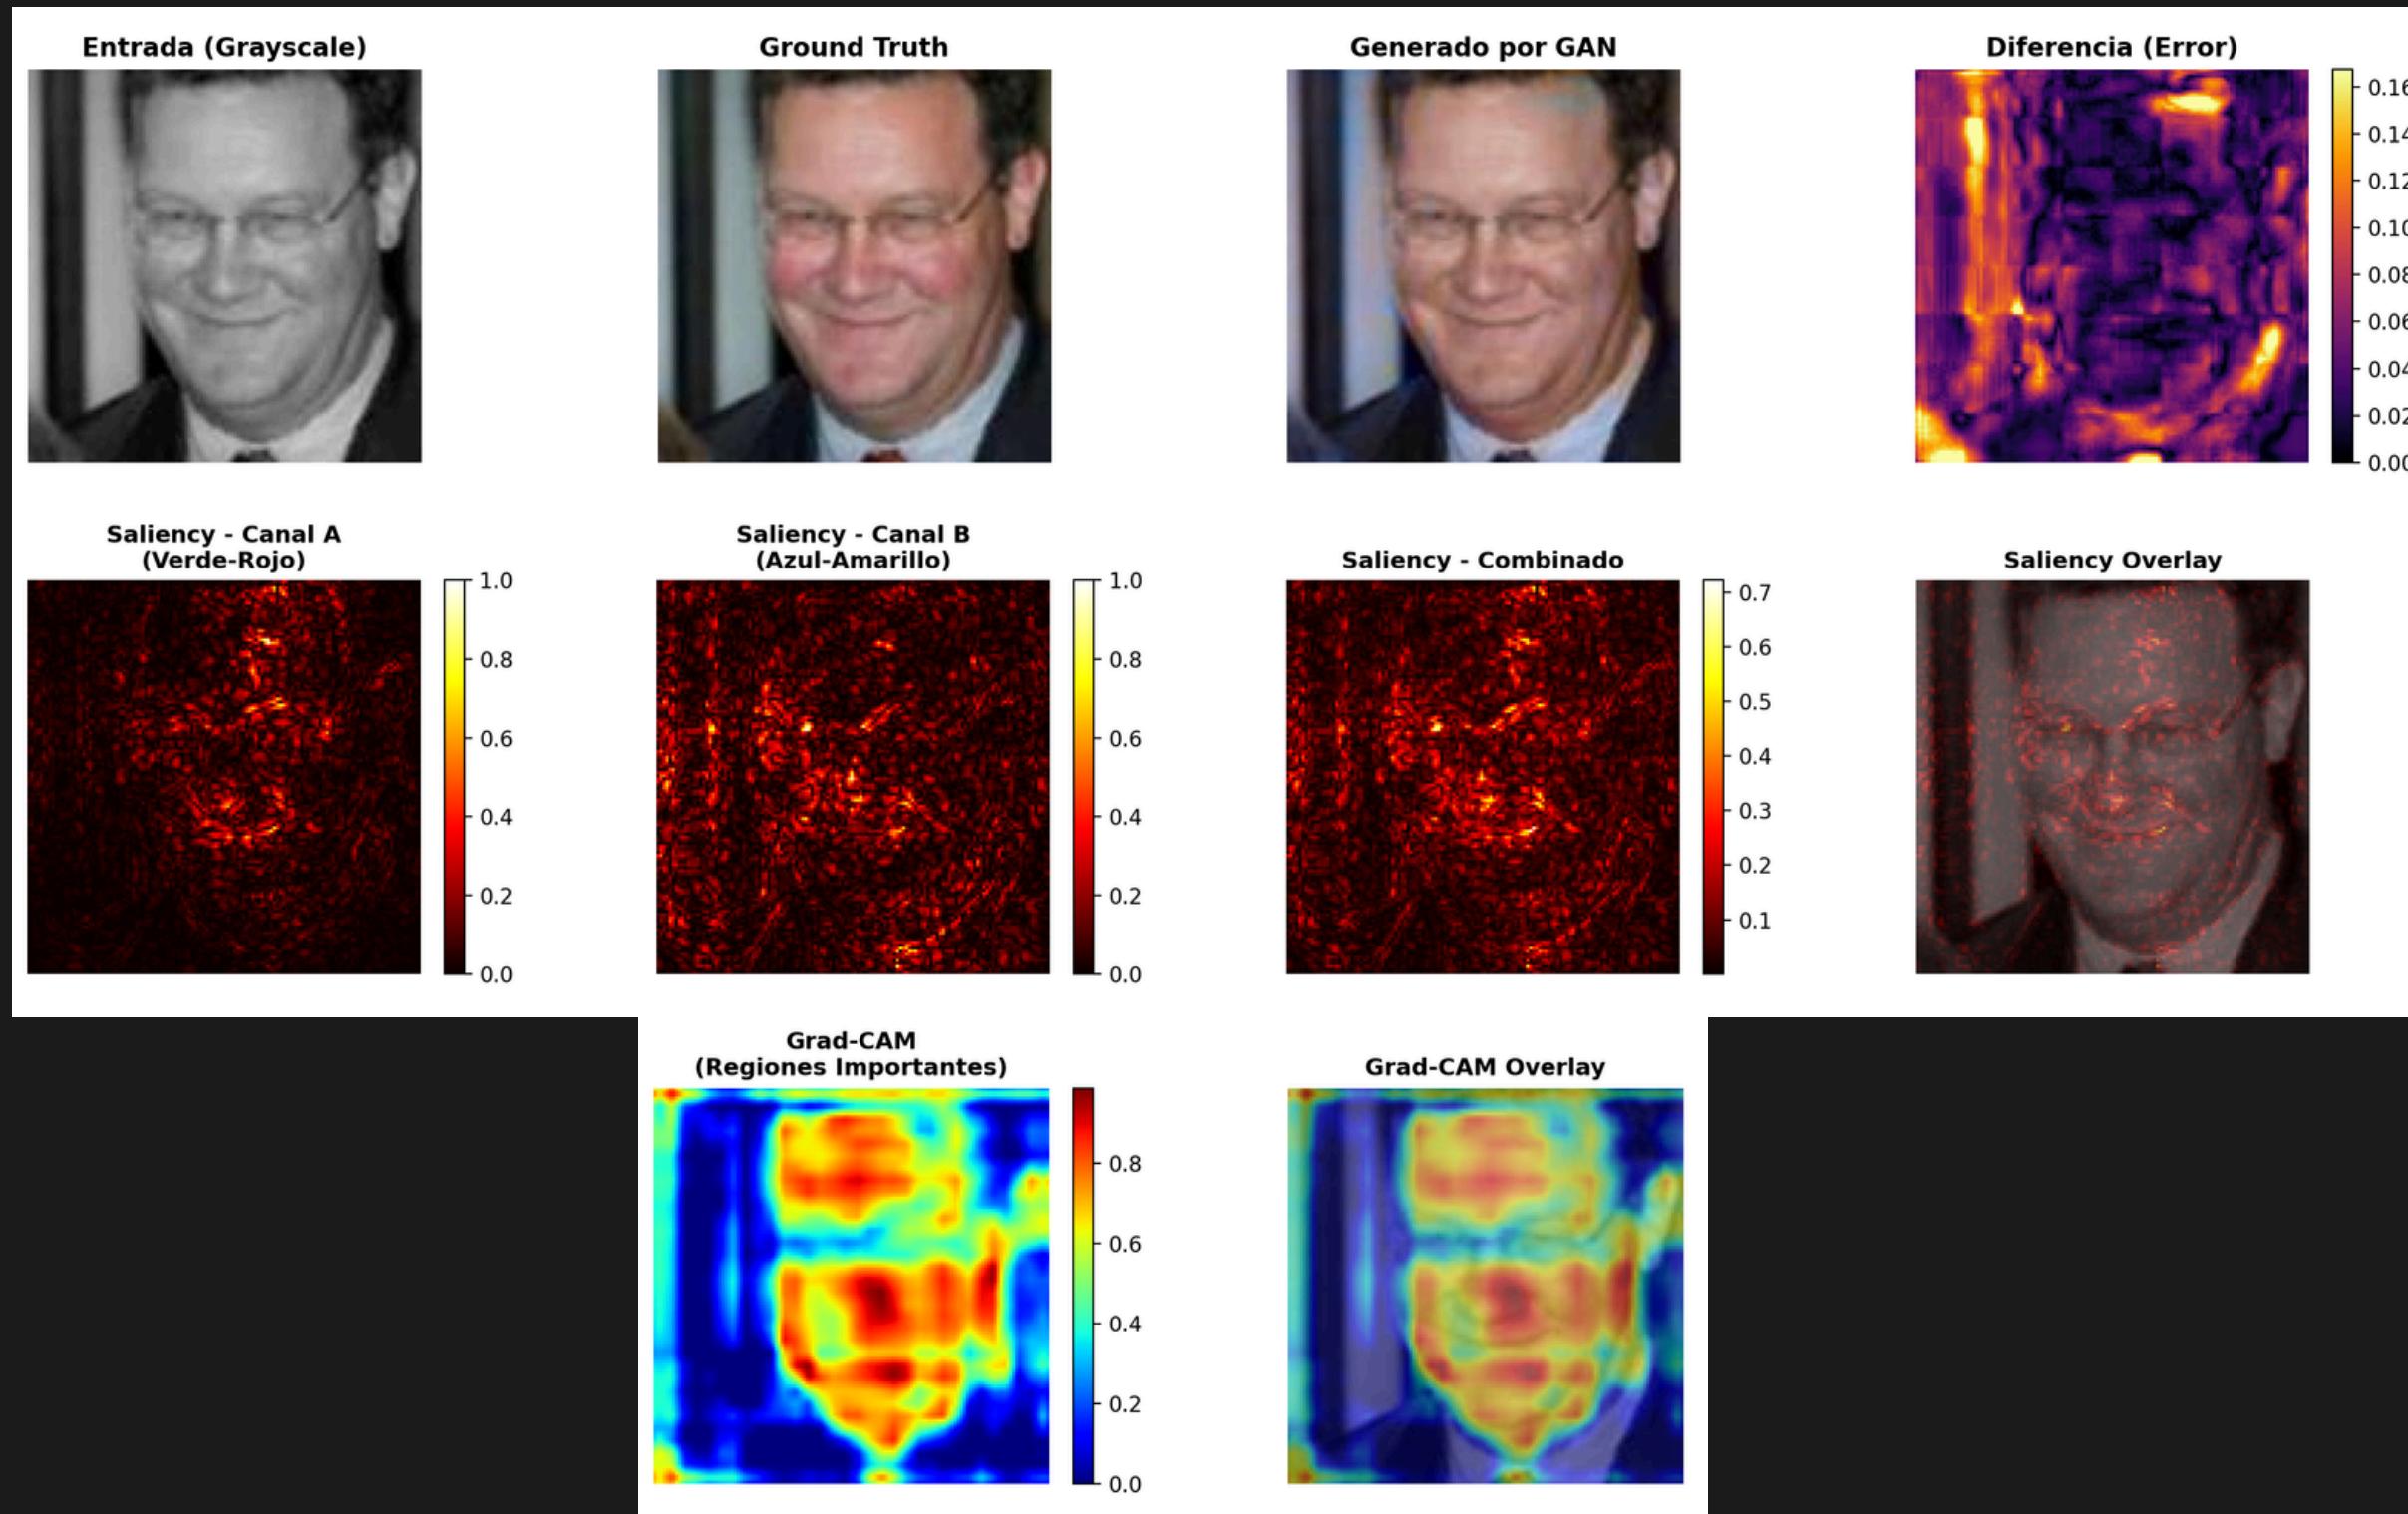
Resultados

Desempeño del modelo y comparación visual



Resultados

Explainable AI



Conclusiones

01

El modelo cGAN con generador VGG16-U-Net y discriminador PatchGAN logró un entrenamiento estable y equilibrado, manteniendo buena generalización y evitando el sobreajuste.

02

Las métricas PSNR y SSIM confirmaron alta fidelidad tonal y estructural, mientras que el Inception Score reflejó diversidad cromática adecuada. Visualmente, las colorizaciones fueron realistas, especialmente en frutas, flores y animales.

03

El análisis de Explainable AI mostró que el modelo enfoca su atención en regiones relevantes y toma decisiones de color guiadas por la estructura y la semántica del objeto.

04

En conjunto, el modelo demostró ser estable, interpretable y capaz de generar colorizaciones visualmente coherentes, sentando una base sólida para futuras mejoras.

¡Muchas gracias!

Grupo #6
Fabiola Contreras
Diego Duarte
José Marchena
Sofía Velásquez
María Villafuerte

